

МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Факультет информационных технологий и прикладной математики
Кафедра вычислительной математики и программирования

**Лабораторная работа №1 по курсу
«Информационный поиск»**

Добыча корпуса документов

Студент: К. А. Арусланов

Группа: М8О-403Б-23

Преподаватель: А. А. Кухтичев

Дата: 20.09.2026

Оценка:

Москва, 2026

Содержание

1	Постановка задачи	2
2	Метод решения	2
2.1	Источники и хранение	2
2.2	Оценка масштаба по sitemap	3
2.3	Формат документа	3
2.4	Разметка и выделение текста	3
3	Результаты	4
3.1	Потенциальный размер корпуса	4
3.2	Статистика проверочной выборки	5
3.3	Существующий поиск	6
3.4	Репозиторий	9
4	Вывод	10

1 Постановка задачи

Необходимо проанализировать корпус документов, который будет использован при выполнении остальных лабораторных работ:

- Скачать примеры документов к себе на компьютер. В отчёте нужно указать источник данных. Источников в итоговом индексе должно быть не менее двух;
- Ознакомиться с ним, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если разметка текста, какая она?
- Выделить текст.
- Найти существующие поисковики, которые уже можно использовать для поиска по выбранному набору документов (встроенный поиск Википедии, поиск Google с использованием ограничений на URL или на сайт). Если такого поиска найти невозможно, то использовать корпус для выполнения лабораторных работ нельзя!
- Привести несколько примеров запросов к существующим поисковикам, указать недостатки в полученной поисковой выдаче.

В результатах работы должна быть указаны статистическая информация о корпусе:

- Размер примеров «сырых» документов.
- Количество документов.
- Размер текста, выделенного из «сырых» данных.
- Средний размер документа, средний объём текста в документе.

2 Метод решения

2.1 Источники и хранение

В качестве тематики корпуса документов выбраны русскоязычные и англоязычные публикации о компьютерных играх. В итоговый список вошли восемь независимых игровых изданий. Русскоязычную часть составляют PlayGround.ru, StopGame.ru, IXBT.games, Игромания и GameMAG; англоязычную — PC Gamer, Eurogamer и GamingOnLinux.

Источник	Язык	Представленные типы публикаций
PlayGround.ru	русский	новости и пользовательские материалы
StopGame.ru	русский	новости, обзоры, статьи и блоги
IXBT.games	русский	новости, статьи и обзоры
Игромания	русский	новости, статьи и обзоры
GameMAG	русский	новости, статьи и обзоры
PC Gamer	английский	игровые новости, статьи и обзоры
Eurogamer	английский	новости, гайды, статьи и обзоры
GamingOnLinux	английский	новости и статьи об играх для Linux

Файл `urls.txt` содержит проверочную выборку из 24 страниц: 3 PlayGround, 5 StopGame, 4 IXBT.games, по 3 Игромании и GameMAG, а также по 2 GamingOnLinux, PC Gamer и Eurogamer. Она нужна для проверки разметки и парсеров; массовый обход на этом этапе не выполняется.

Сбор запускается командой:

```
python main.py collect urls.txt --delay 2
```

Перед запросом программа получает и сохраняет актуальный `robots.txt`, проверяет URL для собственного User-Agent и не запрашивает запрещённые пути. Ответ классифицируется как документ, редирект, 404, 429, 5xx, anti-bot/challenge или запрет robots.txt. CAPTCHA и WAF не обходятся.

Сырой HTML хранится в `data/raw/<source>/`, JSON с результатом разбора — в `data/parsed/<source>/`. Путь к исходному HTML хранится в JSON, поэтому после изменения парсера возможен повторный разбор без сети: `python main.py reparse`.

2.2 Оценка масштаба по sitemap

Перед массовой загрузкой для каждого источника были проверены правила `robots.txt` и объявленные в них sitemap. Программа `discover` обходит только разрешённые XML-карты, выделяет ссылки на публикации и сохраняет их отдельно от HTML. Для каждого сайта используются ограничения по стабильным частям URL или имени sitemap, чтобы не включать страницы тегов, авторов, изображений и служебные страницы. Затем команда `merge-inventories` объединяет локальные инвентари и удаляет совпадающие URL.

Таким образом, оценка размера основана на опубликованных сайтами картах, а не на поисковой выдаче. Это число URL-кандидатов: до скачивания и разбора оно не учитывает возможные HTTP-ошибки, закрытые страницы и близкие по содержанию материалы. Поэтому оно показывает достаточный потенциал для корпуса, но не подменяет статистику реально загруженных документов.

2.3 Формат документа

Все парсеры возвращают источник, URL, заголовок, автора, дату публикации, категорию, теги, связанные игры, основной текст и исходные метаданные. Также записываются HTTP-статус, размеры сырого и выделенного текста, SHA-256 нормализованного текста и ошибка разбора. Удаляются только tracking-параметры URL, а содержательные параметры сохраняются.

2.4 Разметка и выделение текста

Проверка проведена на 24 сохранённых HTML. Для каждого источника подтверждён селектор основного текста и корректность полей заголовка, автора, даты, тегов и категории. В обзорах GameMAG допускается несколько последовательных блоков основного текста; они объединяются в порядке следования. Минимальный объём сохранённой страницы составляет 40 слов: это короткая новость GameMAG 2003 года, а не ошибка извлечения.

Источник	Основной текст	Категория и таксономия
PlayGround	<code>div.article-content</code>	URL: <code>news</code> → news, <code>opinion</code> → review; JSON-LD <code>about.name</code> → games
StopGame	<code>article##material_content</code>	<code>newsdata</code> → news; <code>show</code> с «обзор» → review; теги и игры извлекаются из ссылок
IXBT.games	<code>div[id^="publication-"]</code> <code>.prose</code>	JSON-LD <code>articleSection</code> : новости, статьи, обзоры → news, article, review
Игромания	<code>div[class*="material-content_"]</code>	JSON-LD <code>@type</code> : <code>NewsArticle</code> , <code>Article</code> , <code>Review</code> ; блок тегов → tags
GameMAG	<code>div.content-text</code>	URL: <code>news</code> → news, <code>reviews</code> → review; автор и теги — из блоков страницы
Gaming OnLinux	<code>article.h-entry</code> <code>.e-content</code>	JSON-LD <code>NewsArticle</code> → news; теги — только внутри статьи
PC Gamer	<code>div##article-body</code>	<code>mrf:tags: articleType</code> → news, review; виджеты удаляются
Eurogamer	<code>div.article_body_content</code>	JSON-LD <code>articleSection</code> ; гайды и материалы → article

Для всех сайтов заголовки и служебные поля берутся из `h1`, JSON-LD или мета-тегов. У PlayGround внешний `article` включает комментарии и рекомендации. В IXBT.games числовая часть ID динамическая, а у Игромании динамичен суффикс CSS Modules, поэтому используются устойчивые фрагменты селекторов. Теги Игромании дублируются в desktop/mobile-блоках и дедуплицируются. В StopGame блоки `_read-more` ссылаются на другие материалы и удаляются до извлечения. У PC Gamer дополнительно исключаются блоки «поделиться», реклама, рекомендации, видео и форма рассылки.

3 Результаты

3.1 Потенциальный размер корпуса

По сохранённым sitemap сформирован объединённый инвентарь из **1 055 674 уникальных URL-кандидатов**; совпадающих URL между источниками не обнаружено. Это немного превышает целевой порог в один миллион документов. Наиболее крупные источники — GameMAG и Игромания, однако англоязычные PC Gamer и Eurogamer дают существенный запас объёма.

Источник	URL-кандидатов из sitemap
PlayGround.ru	100 000
StopGame.ru	128 309
IXBT.games	159 496
Игромания	190 628
GameMAG	191 303
PC Gamer	119 841
Eurogamer	137 934
GamingOnLinux	28 163
Всего	1 055 674

3.2 Статистика проверочной выборки

Локально сохранены и разобраны все 24 страницы из `urls.txt`. Повторный разбор выполняется без обращения к сети:

```
python main.py reparse
python main.py stats
```

Показатель	Значение
Количество документов	24
Успешно распарсено / ошибок	24 / 0
Размер сырого HTML	8,94 МБ
Размер выделенного текста	328,3 КБ
Средний raw / text	372,6 / 13,7 КБ
Медиана текста	11,1 КБ
Минимум / максимум текста	0,6 / 59,8 КБ
Слов всего	29 482
Среднее / медиана слов	1 228,4 / 882,5
Точных дубликатов	0
Коэффициент извлечения	3,6713%

Распределение документов: PlayGround — 3, StopGame — 5, IXBT.games — 4, Игромания и GameMAG — по 3, GamingOnLinux, PC Gamer и Eurogamer — по 2. Это техническая выборка для проверки разметки; её нельзя экстраполировать на полный корпус или считать финальным корпусом.

Источник	Док.	Raw, МБ	Текст, КБ	Средний текст, КБ	Слов
PlayGround	3	0,62	34,1	11,4	2 680
StopGame	5	1,29	103,7	20,7	8 524
IXBT.games	4	1,25	59,5	14,9	4 671
Игромания	3	0,78	60,1	20,0	4 717
GameMAG	3	0,30	33,8	11,3	2 630
GamingOnLinux	2	0,15	4,9	2,5	772
PC Gamer	2	4,08	14,5	7,3	2 319
Eurogamer	2	0,48	17,7	8,8	3 169

3.3 Существующий поиск

Корпус доступен во встроенных поисках сайтов и во внешних поисковиках с ограничением `site:.` Для каждого кейса известен документ, который должен быть найден, поэтому недостатки выдачи проверяются сравнением результатов с сохранёнными HTML и выделенным текстом.

Запрос и ожидаемый документ	Наблюдение	Недостаток
«джо кросс»: новости о Джозефе Кроссе на StopGame и Игромании	Внутренний поиск StopGame выдаёт «кроссовер» и «кросс-плей». Яндекс с <code>site:stopgame.ru</code> не находит релевантную новость, а для Игромании показывает один документ. Google показывает релевантные публикации обоих сайтов в первых позициях.	Полнота зависит от поисковой системы; внутренний поиск StopGame плохо обрабатывает вариант имени «Джо/Джозеф Кросс».
«приземлённый подход Insomniac» из статьи IXBT.games о Marvel's Wolverine	Внутренний поиск IXBT.games сообщает «Ничего не найдено», хотя фраза содержится в статье. Яндекс с <code>site:ixbt.games</code> находит её первой.	Внутренний поиск не гарантирует поиск по полному тексту.
«я играю роль поп-звезды, которая убила себя на сцене» из блога StopGame «Музыка Ночного Города»	Внутренний поиск StopGame возвращает несвязанные блоги; Яндекс выводит нужный блог первым.	Даже точная фраза не даёт ожидаемого результата; используемые токенизация и ранжирование непрозрачны.
«леман» на StopGame	Первый результат — «Косплеmania: Chummo...». Искомая последовательность присутствует лишь внутри слова «Косплеmania», а не как сущность «Леман».	Сопоставление подстроки без границ слова даёт тематически нерелевантный результат.
Отбор по типу публикации	В просмотренных интерфейсах IXBT.games и Игромании нет группировки на новости, статьи и блоги; в StopGame есть вкладки типов и сортировка.	Часть внешних и встроенных поисков не использует поля корпуса <code>category</code> , <code>tags</code> , <code>games</code> ; собственной системе нужны фильтры и зонный поиск.





Рис. 1 — Запрос «джо кросс»: нерелевантные результаты встроенного поиска StopGame (слева) и релевантные результаты Google с ограничением на сайт (справа).





Рис. 2 — Точная фраза из статьи IXBT.games не находится внутренним поиском (слева), но находится Яндексом с `site:ixbt.games` (справа).





Рис. 3 — Поиск точной цитаты из блога StopGame: встроенный поиск возвращает другие логи (слева), Яндекс — нужный документ первым (справа).





Рис. 4 — Ложное совпадение по подстроке «леман»: первый результат (слева) и контекст совпадения внутри слова «Косплеmania» (справа).

3.4 Репозиторий

Исходный код, проверочная выборка URL и отчёт размещены в ветке `lab1` репозитория: <https://github.com/kirbasss/MAI-IR/tree/lab1>. Сырые HTML, JSON и инвентари sitemap в репозиторий не добавляются: они занимают много места и должны скачиваться с учётом актуальных правил сайтов.



Рис. 5 — QR-код для перехода к ветке `lab1` репозитория.

4 Вывод

В ходе лабораторной работы я проанализировал структуру игровых публикаций на восьми сайтах и определил HTML-блоки, в которых находятся основной текст, заголовок, дата и другие полезные метаданные. Для этих источников были написаны парсеры, а результаты их работы сохранены в едином формате. Это позволило получить небольшую, но пригодную для дальнейших экспериментов проверочную выборку игрового корпуса.

Отдельно было интересно разобраться с правилами `robots.txt`: перед загрузкой страницы программа получает эти правила и не обращается к запрещённым путям. Проверка встроенного поиска сайтов, Google и Яндекса также показала, почему для корпуса понадобится собственный индекс: поисковая выдача не всегда полна, иногда содержит совпадения по подстроке и не даёт одинаково удобно отбирать новости, статьи и блоги.

Также я научился использовать `robots.txt` и `sitemap` для оценки объёма будущего корпуса. По картам сайтов найдено 1055674 уникальных URL-кандидата, поэтому выбранная тематика и набор источников позволяют собрать корпус требуемого размера. В результате подготовлена воспроизводимая основа для продолжения работы: сохранение исходного HTML, повторный разбор без сети, сбор статистики, оценка масштаба и парсеры для восьми независимых источников.