

МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Факультет информационных технологий и прикладной математики
Кафедра вычислительной математики и программирования

**Лабораторная работа №1 по курсу
«Информационный поиск»**

Добыча корпуса документов

Студент: К. А. Арусланов

Группа: М8О-403Б-23

Преподаватель: А. А. Кухтичев

Дата: 20.09.2026

Оценка:

Москва, 2026

Содержание

1	Постановка задачи	2
2	Метод решения	2
2.1	Источники и хранение	2
2.2	Оценка масштаба по sitemap	3
2.3	Формат документа	3
2.4	Разметка и выделение текста	3
3	Результаты	4
3.1	Потенциальный размер корпуса	4
3.2	Статистика проверочной выборки	5
3.3	Существующий поиск	5
3.4	Репозиторий	8
4	Вывод	8

1 Постановка задачи

Необходимо проанализировать корпус документов, который будет использован при выполнении остальных лабораторных работ:

- Скачать примеры документов к себе на компьютер. В отчёте нужно указать источник данных. Источников в итоговом индексе должно быть не менее двух;
- Ознакомиться с ним, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если разметка текста, какая она?
- Выделить текст.
- Найти существующие поисковики, которые уже можно использовать для поиска по выбранному набору документов (встроенный поиск Википедии, поиск Google с использованием ограничений на URL или на сайт). Если такого поиска найти невозможно, то использовать корпус для выполнения лабораторных работ нельзя!
- Привести несколько примеров запросов к существующим поисковикам, указать недостатки в полученной поисковой выдаче.

В результатах работы должна быть указаны статистическая информация о корпусе:

- Размер примеров «сырых» документов.
- Количество документов.
- Размер текста, выделенного из «сырых» данных.
- Средний размер документа, средний объём текста в документе.

2 Метод решения

2.1 Источники и хранение

В качестве тематики корпуса документов выбраны русскоязычные и англоязычные публикации о компьютерных играх. В итоговый список вошли восемь независимых игровых изданий. Русскоязычную часть составляют PlayGround.ru, StopGame.ru, IXBT.games, Игромания и GameMAG; англоязычную — PC Gamer, Eurogamer и GamingOnLinux.

Источник	Язык	Представленные типы публикаций
PlayGround.ru	русский	новости и пользовательские материалы
StopGame.ru	русский	новости, обзоры, статьи и блоги
IXBT.games	русский	новости, статьи и обзоры
Игромания	русский	новости, статьи и обзоры
GameMAG	русский	новости, статьи и обзоры
PC Gamer	английский	игровые новости, статьи и обзоры
Eurogamer	английский	новости, гайды, статьи и обзоры
GamingOnLinux	английский	новости и статьи об играх для Linux

Файл `urls.txt` содержит проверочную выборку из 24 страниц: 3 PlayGround, 5 StopGame, 4 IXBT.games, по 3 Игромании и GameMAG, а также по 2 GamingOnLinux, PC Gamer и Eurogamer. Она нужна для проверки разметки и парсеров; массовый обход на этом этапе не выполняется.

Сбор запускается командой:

```
python main.py collect urls.txt --delay 2
```

Перед запросом программа получает и сохраняет актуальный `robots.txt`, проверяет URL для собственного User-Agent и не запрашивает запрещённые пути. Ответ классифицируется как документ, редирект, 404, 429, 5xx, anti-bot/challenge или запрет `robots.txt`. CAPTCHA и WAF не обходятся.

Сырой HTML хранится в `data/raw/<source>/`, JSON с результатом разбора — в `data/parsed/<source>/`. Путь к исходному HTML хранится в JSON, поэтому после изменения парсера возможен повторный разбор без сети: `python main.py reparse`.

2.2 Оценка масштаба по sitemap

Перед массовой загрузкой для каждого источника были проверены правила `robots.txt` и объявленные в них sitemap. Программа `discover` обходит только разрешённые XML-карты, выделяет ссылки на публикации и сохраняет их отдельно от HTML. Для каждого сайта используются ограничения по стабильным частям URL или имени sitemap, чтобы не включать страницы тегов, авторов, изображений и служебные страницы. Затем команда `merge-inventories` объединяет локальные инвентари и удаляет совпадающие URL.

Таким образом можно получить число URL-кандидатов: до скачивания и разбора оно не учитывает возможные HTTP-ошибки, закрытые страницы и близкие по содержанию материалы.

2.3 Формат документа

Все парсеры возвращают источник, URL, заголовок, автора, дату публикации, категорию, теги, связанные игры, основной текст и исходные метаданные. Также записываются HTTP-статус, размеры сырого и выделенного текста, SHA-256 нормализованного текста и ошибка разбора. Удаляются только tracking-параметры URL, а содержательные параметры сохраняются.

2.4 Разметка и выделение текста

Проверка проведена на 24 сохранённых HTML. Для каждого источника подтверждён селектор основного текста и корректность полей заголовка, автора, даты, тегов и категории. В обзорах GameMAG допускается несколько последовательных блоков основного текста; они объединяются в порядке следования.

Источник	Основной текст	Категория и таксономия
PlayGround	<code>div.article-content</code>	URL: <code>news</code> → news, <code>opinion</code> → review; JSON-LD <code>about.name</code> → games
StopGame	<code>article##material_content</code>	<code>newsdata</code> → news; <code>show</code> с «обзор» → review; теги и игры извлекаются из ссылок
IXBT.games	<code>div[id^="publication-"]</code> <code>.prose</code>	JSON-LD <code>articleSection</code> : новости, статьи, обзоры → news, article, review
Игромания	<code>div[class*="material-content_"]</code>	JSON-LD <code>@type</code> : <code>NewsArticle</code> , <code>Article</code> , <code>Review</code> ; блок тегов → tags
GameMAG	<code>div.content-text</code>	URL: <code>news</code> → news, <code>reviews</code> → review; автор и теги — из блоков страницы
Gaming OnLinux	<code>article.h-entry</code> <code>.e-content</code>	JSON-LD <code>NewsArticle</code> → news; теги — только внутри статьи
PC Gamer	<code>div##article-body</code>	<code>mrf:tags: articleType</code> → news, review; виджеты удаляются
Eurogamer	<code>div.article_body_content</code>	JSON-LD <code>articleSection</code> ; гайды и материалы → article

Для всех сайтов заголовки и служебные поля берутся из `h1`, JSON-LD или мета-тегов. У PlayGround внешний `article` включает комментарии и рекомендации. В IXBT.games числовая часть ID динамическая, а у Игромании динамичен суффикс CSS Modules, поэтому используются устойчивые фрагменты селекторов. Теги Игромании дублируются в desktop/mobile-блоках и дедуплицируются. В StopGame блоки `_read-more` ссылаются на другие материалы и удаляются до извлечения. У PC Gamer дополнительно исключаются блоки «поделиться», реклама, рекомендации, видео и форма рассылки.

3 Результаты

3.1 Потенциальный размер корпуса

По сохранённым sitemap сформирован объединённый инвентарь из **1 055 674 уникальных URL-кандидатов**; совпадающих URL между источниками не обнаружено. Это немного превышает целевой порог в один миллион документов. Наиболее крупные источники — GameMAG и Игромания, однако англоязычные PC Gamer и Eurogamer дают существенный запас объёма.

Источник	URL-кандидатов из sitemap
PlayGround.ru	100 000
StopGame.ru	128 309
IXBT.games	159 496
Игромания	190 628
GameMAG	191 303
PC Gamer	119 841
Eurogamer	137 934
GamingOnLinux	28 163
Всего	1 055 674

3.2 Статистика проверочной выборки

Локально сохранены и разобраны все 24 страницы из `urls.txt`. Повторный разбор выполняется без обращения к сети:

```
python main.py reparse
python main.py stats
```

Показатель	Значение
Количество документов	24
Успешно распарсено / ошибок	24 / 0
Размер сырого HTML	8,94 МБ
Размер выделенного текста	328,3 КБ
Средний raw / text	372,6 / 13,7 КБ
Медиана текста	11,1 КБ
Минимум / максимум текста	0,6 / 59,8 КБ
Слов всего	29 482
Среднее / медиана слов	1 228,4 / 882,5
Точных дубликатов	0
Коэффициент извлечения	3,6713%

Источник	Док.	Raw, МБ	Текст, КБ	Средний текст, КБ	Слов
PlayGround	3	0,62	34,1	11,4	2 680
StopGame	5	1,29	103,7	20,7	8 524
IXBT.games	4	1,25	59,5	14,9	4 671
Игромания	3	0,78	60,1	20,0	4 717
GameMAG	3	0,30	33,8	11,3	2 630
GamingOnLinux	2	0,15	4,9	2,5	772
PC Gamer	2	4,08	14,5	7,3	2 319
Eurogamer	2	0,48	17,7	8,8	3 169

3.3 Существующий поиск

Корпус доступен во встроенных поисках сайтов и во внешних поисковиках с ограничением `site:..`. Для каждого кейса известен документ, который должен быть

найден, поэтому недостатки выдачи проверяются сравнением результатов с сохранёнными HTML и выделенным текстом.

Запрос и ожидаемый документ	Наблюдение	Недостаток
«джо кросс»: новости о Джозефе Кроссе на StopGame и Игромании	Внутренний поиск StopGame выдаёт «кроссовер» и «кросс-плей». Яндекс с site:stopgame.ru не находит релевантную новость, а для Игромании показывает один документ. Google показывает релевантные публикации обоих сайтов в первых позициях.	Полнота зависит от поисковой системы; внутренний поиск StopGame плохо обрабатывает вариант имени «Джо/Джозеф Кросс».
«приземлённый подход Insomniac» из статьи IXBT.games о Marvel's Wolverine	Внутренний поиск IXBT.games сообщает «Ничего не найдено», хотя фраза содержится в статье. Яндекс с site:ixbt.games находит её первой.	Внутренний поиск не гарантирует поиск по полному тексту.
«я играю роль поп-звезды, которая убила себя на сцене» из блога StopGame «Музыка Ночного Города»	Внутренний поиск StopGame возвращает несвязанные блоги; Яндекс выводит нужный блог первым.	Даже точная фраза не даёт ожидаемого результата; используемые токенизация и ранжирование непрозрачны.
«леман» на StopGame	Первый результат — «Косплеmania: Chumtomo...». Искомая последовательность присутствует лишь внутри слова «Косплеmania», а не как сущность «Леман».	Сопоставление подстроки без границ слова даёт тематически нерелевантный результат.
Отбор по типу публикации	В просмотренных интерфейсах IXBT.games и Игромании нет группировки на новости, статьи и блоги; в StopGame есть вкладки типов и сортировка.	Часть внешних и встроенных поисков не использует поля корпуса category , tags , games ; собственной системе нужны фильтры и зонный поиск.





Рис. 1 — Запрос «джо кросс»: нерелевантные результаты встроенного поиска StopGame (слева) и релевантные результаты Google с ограничением на сайт (справа).





Рис. 2 — Точная фраза из статьи IXBT.games не находится внутренним поиском (слева), но находится Яндексом с `site:ixbt.games` (справа).





Рис. 3 — Поиск точной цитаты из блога StopGame: встроенный поиск возвращает другие логи (слева), Яндекс — нужный документ первым (справа).




Рис. 4 — Ложное совпадение по подстроке «леман»: первый результат (слева) и контекст совпадения внутри слова «Косплемяния» (справа).

3.4 Репозиторий

Исходный код, проверочная выборка URL и отчёт размещены в ветке `lab1` репозитория: <https://github.com/kirbasss/MAI-IR/tree/lab1>.



Рис. 5 — QR-код для перехода к ветке `lab1` репозитория.

4 Вывод

В ходе лабораторной работы я проанализировал структуру игровых публикаций на восьми сайтах и определил HTML-блоки, в которых находятся основной текст, заголовок, дата и другие полезные метаданные. Для этих источников были написаны парсеры, а результаты их работы сохранены в едином формате. Это позволило получить небольшую, но пригодную для дальнейших экспериментов проверочную выборку игрового корпуса.

Отдельно было интересно разобраться с правилами `robots.txt`: перед загрузкой страницы программа получает эти правила и не обращается к запрещённым путям. Проверка встроенного поиска сайтов, Google и Яндексa также показала, почему для корпуса понадобится собственный индекс: поисковая выдача не всегда полна, иногда содержит совпадения по подстроке и не даёт одинаково удобно отбирать новости, статьи и блоги.