

МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ  
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Факультет информационных технологий и прикладной математики  
Кафедра вычислительной математики и программирования

**Лабораторная работа №1 по курсу  
«Информационный поиск»**

**Добыча корпуса документов**

*Студент:* К. А. Арусланов

*Группа:* М8О-403Б-23

*Преподаватель:* А. А. Кухтичев

*Дата:* 20.09.2026

*Оценка:*

Москва, 2026

# Содержание

|          |                                      |          |
|----------|--------------------------------------|----------|
| <b>1</b> | <b>Постановка задачи</b>             | <b>2</b> |
| <b>2</b> | <b>Метод решения</b>                 | <b>2</b> |
| 2.1      | Источники и хранение .....           | 2        |
| 2.2      | Оценка масштаба по sitemap .....     | 3        |
| 2.3      | Формат документа .....               | 3        |
| 2.4      | Разметка и выделение текста .....    | 3        |
| <b>3</b> | <b>Результаты</b>                    | <b>4</b> |
| 3.1      | Потенциальный размер корпуса .....   | 4        |
| 3.2      | Статистика проверочной выборки ..... | 5        |
| 3.3      | Существующий поиск .....             | 5        |
| 3.4      | Репозиторий .....                    | 8        |
| <b>4</b> | <b>Вывод</b>                         | <b>8</b> |

# 1 Постановка задачи

Необходимо проанализировать корпус документов, который будет использован при выполнении остальных лабораторных работ:

- Скачать примеры документов к себе на компьютер. В отчёте нужно указать источник данных. Источников в итоговом индексе должно быть не менее двух;
- Ознакомиться с ним, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если разметка текста, какая она?
- Выделить текст.
- Найти существующие поисковики, которые уже можно использовать для поиска по выбранному набору документов (встроенный поиск Википедии, поиск Google с использованием ограничений на URL или на сайт). Если такого поиска найти невозможно, то использовать корпус для выполнения лабораторных работ нельзя!
- Привести несколько примеров запросов к существующим поисковикам, указать недостатки в полученной поисковой выдаче.

В результатах работы должна быть указаны статистическая информация о корпусе:

- Размер примеров «сырых» документов.
- Количество документов.
- Размер текста, выделенного из «сырых» данных.
- Средний размер документа, средний объём текста в документе.

## 2 Метод решения

### 2.1 Источники и хранение

В качестве тематики корпуса документов выбраны русскоязычные и англоязычные публикации о компьютерных играх. В итоговый список вошли восемь независимых игровых изданий. Русскоязычную часть составляют PlayGround.ru, StopGame.ru, IXBT.games, Игромания и GameMAG; англоязычную — PC Gamer, Eurogamer и GamingOnLinux.

| Источник      | Язык       | Представленные типы публикаций       |
|---------------|------------|--------------------------------------|
| PlayGround.ru | русский    | новости и пользовательские материалы |
| StopGame.ru   | русский    | новости, обзоры, статьи и блоги      |
| IXBT.games    | русский    | новости, статьи и обзоры             |
| Игромания     | русский    | новости, статьи и обзоры             |
| GameMAG       | русский    | новости, статьи и обзоры             |
| PC Gamer      | английский | игровые новости, статьи и обзоры     |
| Eurogamer     | английский | новости, гайды, статьи и обзоры      |
| GamingOnLinux | английский | новости и статьи об играх для Linux  |

Файл `urls.txt` содержит проверочную выборку из 24 страниц: 3 PlayGround, 5 StopGame, 4 IXBT.games, по 3 Игромании и GameMAG, а также по 2 GamingOnLinux, PC Gamer и Eurogamer. Она нужна для проверки разметки и парсеров; массовый обход на этом этапе не выполняется.

Сбор запускается командой:

```
python main.py collect urls.txt --delay 2
```

Перед запросом программа получает и сохраняет актуальный `robots.txt`, проверяет URL для собственного User-Agent и не запрашивает запрещённые пути. Ответ классифицируется как документ, редирект, 404, 429, 5xx, anti-bot/challenge или запрет `robots.txt`. CAPTCHA и WAF не обходятся.

Сырой HTML хранится в `data/raw/<source>/`, JSON с результатом разбора — в `data/parsed/<source>/`. Путь к исходному HTML хранится в JSON, поэтому после изменения парсера возможен повторный разбор без сети: `python main.py reparse`.

## 2.2 Оценка масштаба по sitemap

Перед массовой загрузкой для каждого источника были проверены правила `robots.txt` и объявленные в них sitemap. Программа `discover` обходит только разрешённые XML-карты, выделяет ссылки на публикации и сохраняет их отдельно от HTML. Для каждого сайта используются ограничения по стабильным частям URL или имени sitemap, чтобы не включать страницы тегов, авторов, изображений и служебные страницы. Затем команда `merge-inventories` объединяет локальные инвентари и удаляет совпадающие URL.

Таким образом можно получить число URL-кандидатов: до скачивания и разбора оно не учитывает возможные HTTP-ошибки, закрытые страницы и близкие по содержанию материалы.

## 2.3 Формат документа

Все парсеры возвращают источник, URL, заголовок, автора, дату публикации, категорию, теги, связанные игры, основной текст и исходные метаданные. Также записываются HTTP-статус, размеры сырого и выделенного текста, SHA-256 нормализованного текста и ошибка разбора. Удаляются только tracking-параметры URL, а содержательные параметры сохраняются.

## 2.4 Разметка и выделение текста

Проверка проведена на 24 сохранённых HTML. Для каждого источника подтверждён селектор основного текста и корректность полей заголовка, автора, даты, тегов и категории. В обзорах GameMAG допускается несколько последовательных блоков основного текста; они объединяются в порядке следования.

| Источник       | Основной текст                               | Категория и таксономия                                                                                                 |
|----------------|----------------------------------------------|------------------------------------------------------------------------------------------------------------------------|
| PlayGround     | <code>div.article-content</code>             | URL: <code>news</code> → news, <code>opinion</code> → review; JSON-LD <code>about.name</code> → games                  |
| StopGame       | <code>article##material_content</code>       | <code>newsdata</code> → news; <code>show</code> с «обзор» → review; теги и игры извлекаются из ссылок                  |
| IXBT.games     | <code>div[id^="publication-"].prose</code>   | JSON-LD <code>articleSection</code> : новости, статьи, обзоры → news, article, review                                  |
| Игромания      | <code>div[class*="material-content_"]</code> | JSON-LD <code>@type</code> : <code>NewsArticle</code> , <code>Article</code> , <code>Review</code> ; блок тегов → tags |
| GameMAG        | <code>div.content-text</code>                | URL: <code>news</code> → news, <code>reviews</code> → review; автор и теги — из блоков страницы                        |
| Gaming OnLinux | <code>article.h-entry.e-content</code>       | JSON-LD <code>NewsArticle</code> → news; теги — только внутри статьи                                                   |
| PC Gamer       | <code>div##article-body</code>               | <code>mrf:tags: articleType</code> → news, review; виджеты удаляются                                                   |
| Eurogamer      | <code>div.article_body_content</code>        | JSON-LD <code>articleSection</code> ; гайды и материалы → article                                                      |

Для всех сайтов заголовки и служебные поля берутся из `h1`, JSON-LD или мета-тегов. У PlayGround внешний `article` включает комментарии и рекомендации. В IXBT.games числовая часть ID динамическая, а у Игромании динамичен суффикс CSS Modules, поэтому используются устойчивые фрагменты селекторов. Теги Игромании дублируются в desktop/mobile-блоках и дедуплицируются. В StopGame блоки `_read-more` ссылаются на другие материалы и удаляются до извлечения. У PC Gamer дополнительно исключаются блоки «поделиться», реклама, рекомендации, видео и форма рассылки.

## 3 Результаты

### 3.1 Потенциальный размер корпуса

По сохранённым sitemap сформирован объединённый инвентарь из **1 055 674 уникальных URL-кандидатов**; совпадающих URL между источниками не обнаружено. Это немного превышает целевой порог в один миллион документов. Наиболее крупные источники — GameMAG и Игромания, однако англоязычные PC Gamer и Eurogamer дают существенный запас объёма.

| Источник      | URL-кандидатов из sitemap |
|---------------|---------------------------|
| PlayGround.ru | 100 000                   |
| StopGame.ru   | 128 309                   |
| IXBT.games    | 159 496                   |
| Игромания     | 190 628                   |
| GameMAG       | 191 303                   |
| PC Gamer      | 119 841                   |
| Eurogamer     | 137 934                   |
| GamingOnLinux | 28 163                    |
| <b>Всего</b>  | <b>1 055 674</b>          |

### 3.2 Статистика проверочной выборки

Локально сохранены и разобраны все 24 страницы из `urls.txt`. Повторный разбор выполняется без обращения к сети:

```
python main.py reparse
python main.py stats
```

| Показатель                  | Значение        |
|-----------------------------|-----------------|
| Количество документов       | 24              |
| Успешно распарсено / ошибок | 24 / 0          |
| Размер сырого HTML          | 8,94 МБ         |
| Размер выделенного текста   | 328,3 КБ        |
| Средний raw / text          | 372,6 / 13,7 КБ |
| Медиана текста              | 11,1 КБ         |
| Минимум / максимум текста   | 0,6 / 59,8 КБ   |
| Слов всего                  | 29 482          |
| Среднее / медиана слов      | 1 228,4 / 882,5 |
| Точных дубликатов           | 0               |
| Коэффициент извлечения      | 3,6713%         |

| Источник      | Док. | Raw, МБ | Текст, КБ | Средний текст, КБ | Слов  |
|---------------|------|---------|-----------|-------------------|-------|
| PlayGround    | 3    | 0,62    | 34,1      | 11,4              | 2 680 |
| StopGame      | 5    | 1,29    | 103,7     | 20,7              | 8 524 |
| IXBT.games    | 4    | 1,25    | 59,5      | 14,9              | 4 671 |
| Игромания     | 3    | 0,78    | 60,1      | 20,0              | 4 717 |
| GameMAG       | 3    | 0,30    | 33,8      | 11,3              | 2 630 |
| GamingOnLinux | 2    | 0,15    | 4,9       | 2,5               | 772   |
| PC Gamer      | 2    | 4,08    | 14,5      | 7,3               | 2 319 |
| Eurogamer     | 2    | 0,48    | 17,7      | 8,8               | 3 169 |

### 3.3 Существующий поиск

Корпус доступен во встроенных поисках сайтов и во внешних поисковиках с ограничением `site:..`. Для каждого кейса известен документ, который должен быть

найден, поэтому недостатки выдачи проверяются сравнением результатов с сохранёнными HTML и выделенным текстом.

| Запрос и ожидаемый документ                                                                      | Наблюдение                                                                                                                                                                                                                                       | Недостаток                                                                                                                                     |
|--------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------|
| «джо кросс»: новости о Джозефе Кроссе на StopGame и Игромании                                    | Внутренний поиск StopGame выдаёт «кроссовер» и «кросс-плей». Яндекс с <b>site:stopgame.ru</b> не находит релевантную новость, а для Игромании показывает один документ. Google показывает релевантные публикации обоих сайтов в первых позициях. | Полнота зависит от поисковой системы; внутренний поиск StopGame плохо обрабатывает вариант имени «Джо/Джозеф Кросс».                           |
| «приземлённый подход Insomniac» из статьи IXBT.games о Marvel's Wolverine                        | Внутренний поиск IXBT.games сообщает «Ничего не найдено», хотя фраза содержится в статье. Яндекс с <b>site:ixbt.games</b> находит её первой.                                                                                                     | Внутренний поиск не гарантирует поиск по полному тексту.                                                                                       |
| «я играю роль поп-звезды, которая убила себя на сцене» из блога StopGame «Музыка Ночного Города» | Внутренний поиск StopGame возвращает несвязанные блоги; Яндекс выводит нужный блог первым.                                                                                                                                                       | Даже точная фраза не даёт ожидаемого результата; используемые токенизация и ранжирование непрозрачны.                                          |
| «леман» на StopGame                                                                              | Первый результат — «Косплеания: Chumtomo...». Искомая последовательность присутствует лишь внутри слова «Косплеания», а не как сущность «Леман».                                                                                                 | Сопоставление подстроки без границ слова даёт тематически нерелевантный результат.                                                             |
| Отбор по типу публикации                                                                         | В просмотренных интерфейсах IXBT.games и Игромании нет группировки на новости, статьи и блоги; в StopGame есть вкладки типов и сортировка.                                                                                                       | Часть внешних и встроенных поисков не использует поля корпуса <b>category, tags, games</b> ; собственной системе нужны фильтры и зонный поиск. |





Рис. 1 — Запрос «джо кросс»: нерелевантные результаты встроенного поиска StopGame (слева) и релевантные результаты Google с ограничением на сайт (справа).





Рис. 2 — Точная фраза из статьи IXBT.games не находится внутренним поиском (слева), но находится Яндексом с `site:ixbt.games` (справа).





Рис. 3 — Поиск точной цитаты из блога StopGame: встроенный поиск возвращает другие логи (слева), Яндекс — нужный документ первым (справа).




Рис. 4 — Ложное совпадение по подстроке «леман»: первый результат (слева) и контекст совпадения внутри слова «Косплемяния» (справа).

### 3.4 Репозиторий

Исходный код, проверочная выборка URL и отчёт размещены в ветке `lab1` репозитория: <https://github.com/kirbasss/MAI-IR/tree/lab1>. Сырые HTML, JSON и инвентари sitemap в репозиторий не добавляются: они занимают много места и должны скачиваться с учётом актуальных правил сайтов.




Рис. 5 — QR-код для перехода к ветке `lab1` репозитория.

## 4 Вывод

В ходе лабораторной работы я проанализировал структуру игровых публикаций на восьми сайтах и определил HTML-блоки, в которых находятся основной текст, заголовок, дата и другие полезные метаданные. Для этих источников были написаны парсеры, а результаты их работы сохранены в едином формате. Это позволило получить небольшую, но пригодную для дальнейших экспериментов проверочную выборку игрового корпуса.

Отдельно было интересно разобраться с правилами `robots.txt`: перед загрузкой страницы программа получает эти правила и не обращается к запрещённым путям. Проверка встроенного поиска сайтов, Google и Яндекса также показала, почему для корпуса понадобится собственный индекс: поисковая выдача не всегда полна, иногда содержит совпадения по подстроке и не даёт одинаково удобно отбирать новости, статьи и блоги.