

МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Факультет информационных технологий и прикладной математики
Кафедра вычислительной математики и программирования

**Лабораторная работа №1 по курсу
«Информационный поиск»**

Добыча корпуса документов

Студент: К. А. Арусланов

Группа: М8О-403Б-23

Преподаватель: А. А. Кухтичев

Дата: 19.09.2026

Оценка:

Москва, 2026

Содержание

1 Постановка задачи

Необходимо проанализировать корпус документов, который будет использован при выполнении остальных лабораторных работ:

- Скачать примеры документов к себе на компьютер. В отчёте нужно указать источник данных. Источников в итоговом индексе должно быть не менее двух;
- Ознакомиться с ним, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если разметка текста, какая она?
- Выделить текст.
- Найти существующие поисковики, которые уже можно использовать для поиска по выбранному набору документов (встроенный поиск Википедии, поиск Google с использованием ограничений на URL или на сайт). Если такого поиска найти невозможно, то использовать корпус для выполнения лабораторных работ нельзя!
- Привести несколько примеров запросов к существующим поисковикам, указать недостатки в полученной поисковой выдаче.

В результатах работы должна быть указаны статистическая информация о корпусе:

- Размер примеров «сырых» документов.
- Количество документов.
- Размер текста, выделенного из «сырых» данных.
- Средний размер документа, средний объём текста в документе.

2 Метод решения

2.1 Источники и хранение

В качестве тематики корпуса документов выбраны русскоязычные публикации о компьютерных играх.

Кандидатами являются PlayGround.ru, StopGame.ru, IXBT.games и Игромания. В окончательном корпусе будет не менее двух независимых источников. Файл `urls.txt` содержит проверочную выборку из 15 страниц: 3 PlayGround, 5 StopGame, 4 IXBT.games и 3 Игромании. Массовый обход на этапе лабораторной работы не выполняется.

Сбор запускается командой:

```
python main.py collect urls.txt --delay 2
```

Перед запросом программа получает и сохраняет актуальный `robots.txt`, проверяет URL для собственного User-Agent и не запрашивает запрещённые пути. Ответ классифицируется как документ, редирект, 404, 429, 5xx, anti-bot/challenge или запрет robots.txt. CAPTCHA и WAF не обходятся.

Сырой HTML хранится в `data/raw/<source>/`, JSON с результатом разбора — в `data/parsed/<source>/`. Путь к исходному HTML хранится в JSON, поэтому после изменения парсера возможен повторный разбор без сети: `python main.py reparse`.

2.2 Формат документа

Все парсеры возвращают источник, URL, заголовок, автора, дату публикации, категорию, теги, связанные игры, основной текст и исходные метаданные. Также записываются HTTP-статус, размеры сырого и выделенного текста, SHA-256 нормализованного текста и ошибка разбора. Удаляются только tracking-параметры URL, а содержательные параметры сохраняются.

2.3 Разметка и выделение текста

Проверка проведена на 15 сохранённых HTML. В выборку вошли по 3 страницы PlayGround и Игромании, 4 IXBT.games и 5 StopGame. В каждом документе найден ровно один контейнер основного текста и выделено более 100 слов.

Источник	Основной текст	Категория и таксономия
PlayGround	<code>div.article-content</code>	URL: <code>news</code> → news, <code>opinion</code> → review; JSON-LD <code>about.name</code> → games
StopGame	<code>article##material_content</code>	<code>newsdata</code> → news; <code>show</code> с «обзор» → review; теги и игры извлекаются из ссылок
IXBT.games .prose	<code>div[id^="publication-"]</code> JSON-LD <code>articleSection</code> : новости, статьи, обзоры → news, article, review	
Игромания <code>content_</code> "]	<code>div[class*="material- content_"]</code> JSON-LD <code>@type</code> : <code>NewsArticle</code> , <code>Article</code> , <code>Review</code> ; блок тегов → tags	

Для всех сайтов заголовки и служебные поля берутся из `h1` и JSON-LD `headline`, `author`, `datePublished`. У PlayGround внешний `article` включает комментарии и рекомендации. В IXBT.games числовая часть ID динамическая, а у Игромании динамичен суффикс CSS Modules, поэтому используются устойчивые фрагменты селекторов. Теги Игромании дублируются в desktop/mobile-блоках и дедулицируются. В StopGame блоки `_read-more` ссылаются на другие материалы и удаляются до извлечения.

3 Результаты

3.1 Статистика проверочной выборки

Локально сохранены и разобраны все 15 страниц из `urls.txt`. Повторный разбор выполняется без обращения к сети:

```
python main.py reparse
python main.py stats
```

Показатель	Значение
Количество документов	15
Успешно распарсено / ошибок	15 / 0
Размер сырого HTML	3,90 МБ
Размер выделенного текста	257,3 КБ
Средний raw / text	260,2 / 17,2 КБ
Медиана текста	11,6 КБ
Минимум / максимум текста	1,8 / 59,8 КБ
Слов всего	20 592
Среднее / медиана слов	1 372,8 / 943
Точных дубликатов	0
Коэффициент извлечения	6.5937%

Распределение документов: PlayGround — 3, StopGame — 5, IXBT.games — 4, Игромания — 3. Это техническая выборка для проверки разметки; её нельзя экстраполировать на миллион документов или считать финальным корпусом.

Источник	Док.	Raw, МБ	Текст, КБ	Средний текст, КБ	Слов
PlayGround	3	0,64	34,1	11,4	2 680
StopGame	5	1,25	103,7	20,7	8 524
IXBT.games	4	1,24	59,5	14,9	4 671
Игромания	3	0,77	60,1	20,0	4 717

3.2 Существующий поиск

Корпус доступен во встроенных поисках сайтов и во внешних поисковиках с ограничением `site:.` Для каждого кейса известен документ, который должен быть найден, поэтому недостатки выдачи проверяются сравнением результатов с сохранёнными HTML и выделенным текстом.

Запрос и ожидаемый документ	Наблюдение	Недостаток
«джо кросс»: новости о Джозефе Кроссе на StopGame и Игромании	Внутренний поиск StopGame выдаёт «кроссовер» и «кросс-плей». Яндекс с <code>site:stopgame.ru</code> не находит релевантную новость, а для Игромании показывает один документ. Google показывает релевантные публикации обоих сайтов в первых позициях.	Полнота зависит от поисковой системы; внутренний поиск StopGame плохо обрабатывает вариант имени «Джо/Джозеф Кросс».

Запрос и ожидаемый документ	Наблюдение	Недостаток
«приземлённый подход Insomniac» из статьи IXBT.games о Marvel's Wolverine	Внутренний поиск IXBT.games сообщает «Ничего не найдено», хотя фраза содержится в статье. Яндекс с <code>site:ixbt.games</code> находит её первой.	Внутренний поиск не гарантирует поиск по полному тексту.
«я играю роль поп-звезды, которая убила себя на сцене» из блога StopGame «Музыка Ночного Города»	Внутренний поиск StopGame возвращает несвязанные блоги; Яндекс выводит нужный блог первым.	Даже точная фраза не даёт ожидаемого результата; используемые токенизация и ранжирование непрозрачны.
«леман» на StopGame	Первый результат — «Косплеяния: Chumtomo...». Искомая последовательность присутствует лишь внутри слова «Косплеяния», а не как сущность «Леман».	Сопоставление подстроки без границ слова даёт тематически нерелевантный результат.
Отбор по типу публикации	В просмотренных интерфейсах IXBT.games и Игромании нет группировки на новости, статьи и блоги; в StopGame есть вкладки типов и сортировка.	Часть внешних и встроенных поисков не использует поля корпуса <code>category, tags, games</code> ; собственной системе нужны фильтры и зонный поиск.




Рис. 1 — Запрос «джо кросс»: нерелевантные результаты встроенного поиска StopGame (слева) и релевантные результаты Google с ограничением на сайт (справа).





Рис. 2 — Точная фраза из статьи IXBT.games не находится внутренним поиском (слева), но находится Яндексом с `site:ixbt.games` (справа).





Рис. 3 — Поиск точной цитаты из блога StopGame: встроенный поиск возвращает другие логи (слева), Яндекс — нужный документ первым (справа).





Рис. 4 — Ложное совпадение по подстроке «леман»: первый результат (слева) и контекст совпадения внутри слова «Косплеяния» (справа).

4 Вывод

В ходе лабораторной работы я проанализировал структуру игровых публикаций на четырёх сайтах и определил HTML-блоки, в которых находятся основной текст, заголовок, дата и другие полезные метаданные. Для этих источников был написан парсер, а результаты его работы сохранены в едином формате. Это позволило получить небольшую, но пригодную для дальнейших экспериментов выборку игрового корпуса.

Отдельно было интересно разобраться с правилами `robots.txt`: перед загрузкой страницы программа получает эти правила и не обращается к запрещённым путям. Проверка встроенного поиска сайтов, Google и Яндекса также показала, почему для корпуса понадобится собственный индекс: поисковая выдача не всегда полна, иногда содержит совпадения по подстроке и не даёт одинаково удобно отбирать новости, статьи и блоги.

В результате подготовлена воспроизводимая основа для продолжения работы: сохранение исходного HTML, повторный разбор без сети, сбор статистики и парсеры для четырёх независимых источников.