

МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Факультет информационных технологий и прикладной математики
Кафедра вычислительной математики и программирования

**Лабораторная работа №2 по курсу
«Информационный поиск»**

Поисковый робот

Студент: К. А. Арусланов

Группа: М8О-403Б-23

Преподаватель: А. А. Кухтичев

Дата: 08.10.2026

Оценка:

Москва, 2026

Содержание

1	Постановка задачи	2
2	Метод решения	2
2.1	Источники и входные данные	2
2.2	Очередь и сохранение документов.....	2
2.3	Проверка изменений.....	3
2.4	Проверка работы	3
3	Результаты	3
3.1	Запуск и автотесты	3
3.2	Пробная обкачка	4
3.3	Репозиторий	5
4	Вывод	5

1 Постановка задачи

Для корпуса игровых публикаций из первой лабораторной работы требуется разработать поисковый робот:

- реализовать обкачку документов;
- принимать при обычном запуске один аргумент — путь к YAML-файлу с данными базы в секции `db` и параметрами робота в секции `logic`, в том числе задержкой между запросами;
- сохранять в базе нормализованный URL, сырой HTML, название источника и дату загрузки в формате Unix timestamp;
- после остановки продолжать обход с незавершённого документа;
- периодически проверять загруженные страницы и обновлять сохранённые документы только при изменении содержимого.

2 Метод решения

2.1 Источники и входные данные

В качестве корпуса выбраны публикации восьми игровых сайтов: PlayGround, StopGame, IXBT.games, Игромания, GameMAG, PC Gamer, Eurogamer и GamingOnLinux. Входом служит UTF-8 TSV-файл: короткий `urls.txt` из первой лабораторной либо объединённый инвентарь `sitemap`. Последний содержит 1055674 URL-кандидата, но это ещё не число пригодных документов.

Файл читается построчно и импортируется в MongoDB партиями, без загрузки всего списка в память. URL очищается от параметров отслеживания, его хост сверяется с разрешённым списком. Для новостей StopGame дополнительно исправляется встречающийся в `sitemap` префикс `/news/` на рабочий `/newsdata/`. Пробная выборка воспроизводима по заданному `seed`; порядок очереди перемешивается устойчивым хешем URL.

2.2 Очередь и сохранение документов

Для хранения выбрана MongoDB. Очередь и содержимое страницы разделены по коллекциям, чтобы просмотр результатов разбора не загружал большой HTML:

Коллекция	Содержимое
<code>frontier</code>	URL, источник, состояние, время следующей попытки, число попыток, HTTP-заголовки и последняя ошибка
<code>raw_pages</code>	Нормализованный URL, источник, Unix-время загрузки, сырой HTML и SHA-256 ответа
<code>documents</code>	Результат разбора, HTTP-метаданные, время загрузки и ссылка <code>raw_page_id</code> на исходный HTML
<code>crawler_meta</code>	Метка импорта инвентаря и паузы для отдельных сайтов

Ключ `_id` у заданий и документов равен нормализованному URL, поэтому повторная загрузка не создаёт дубликатов. Сначала сохраняется сырой HTML, затем результат разбора и только после этого завершается задание очереди. Если выполнение прервётся между этими шагами, при следующей попытке согласованность записей проверяется по SHA-256.

Робот атомарно выбирает доступный URL и отмечает его как обрабатываемый. Затем он проверяет `robots.txt` и делает запрос с паузой для каждого хоста. Редиректы проверяются по отдельности: переход за пределы источника не выполняется. При перезапуске незавершённые URL возвращаются в начало очереди. Механизм рассчитан на один процесс робота.

2.3 Проверка изменений

При повторном запросе робот использует сохранённые ETag и Last-Modified. Ответ 304 оставляет HTML неизменным. Если сервер возвращает 200, вычисляется SHA-256 исходного ответа: при совпадении хеша обе записи не перезаписываются. Для изменённого ответа обновляются `raw_pages`, `documents` и `fetches_at`. Если одна из двух записей отсутствует либо их хеши расходятся, робот повторно получает HTML и восстанавливает согласованное состояние. Время каждой проверки хранится в `frontier.last_checked_at`. При ошибках попытка откладывается: 404/410 и запрет `robots.txt` проверяются реже, для 429 учитывается `Retry-After`. Пауза одного источника хранится в MongoDB и не останавливает другие сайты.

2.4 Проверка работы

При переносе компонентов из `lab1` в `lab2` добавлены парсеры GameMAG, GamingOnLinux, PC Gamer и Eurogamer. Для нового робота написаны отдельные тесты с имитацией MongoDB и HTTP-ответов. Проверяются:

- чтение YAML и оба формата входного TSV;
- загрузка и сохранение обязательных полей;
- повторный запуск после завершения и после остановки на URL;
- ответы 304, неизменённый 200 и изменённый 200;
- запрет `robots.txt`, отличие текстовых правил от HTML-заглушки и отложенная попытка после 429;
- пауза для одного источника без остановки других сайтов и воспроизводимость выборки URL.

3 Результаты

3.1 Запуск и автотесты

Код робота запускается командой `python crawler.py crawler.example.yaml`. В примере ограничение `max_documents: 10` позволяет проверить небольшую часть

списка `urls.txt`. Команда `python run_tests.py` проверяет систему без сервера MongoDB и без обращений к сайтам.

Успешно прошли 48 тестов, из них 18 проверяют робота. Сценарии охватывают сохранение HTML и времени Unix, продолжение после остановки, ответы 304 и 200, контрольную сумму, `robots.txt` и `Retry-After`. Локальные HTML-образцы первой работы проверяются прежними тестами.

3.2 Пробная обкачка

MongoDB запускалась локально через Docker Compose. Сначала робот сохранил 24 проверочные страницы из `urls.txt`, затем выборка была расширена. На 8 октября 2026 года в очереди находилось 824 URL: 374 завершённых, 449 ожидающих и один оставшийся в обработке после остановки. Большой инвентарь в миллион URL в базу пока не импортировался.

Источник	Скачано	С текстом	Без текста
PlayGround	46	42	4
StopGame	51	51	0
IXBT.games	46	46	0
Игромания	36	36	0
GameMAG	54	53	1
PC Gamer	56	52	4
Eurogamer	39	36	3
GamingOnLinux	46	45	1
Vсero	374	361	13

Все 374 записи `documents` имеют соответствующие страницы `raw_pages`; их контрольные суммы совпадают, пустого HTML и потерянных исходных страниц нет. У 13 документов HTML получен, но парсер не нашёл основной текст. Среди них есть карточки игр и страницы категорий, которые нужно исключить из инвентаря, а также публикации с необычной разметкой или преимущественно медийным содержанием. Поэтому для будущего поискового индекса пригодность URL надо проверять после загрузки, а не оценивать только по sitemap.

Первоначальные 124 записи были перенесены из формата со встроенным HTML в отдельные коллекции после резервного копирования базы. Средний размер записи в `documents` уменьшился примерно с 470 до 7 КБ, что удобнее для просмотра результатов разбора. Дополнительно 71681 URL новостей StopGame в полном инвентаре и 57 старых заданий очереди приведены к рабочему виду `/newsdata/`; исходные задания сохранены для восстановления.

3.3 Репозиторий

Исходный код, конфигурации, тесты и отчёт размещены в ветке `lab2` репозитория: <https://github.com/kirbasss/MAI-IR/tree/lab2>. Сырые страницы и содержимое базы данных в GitHub не загружаются.



Рис. 1 — QR-код для перехода к ветке `lab2` репозитория.

4 Вывод

В этой работе я дополнил сбор игровых публикаций устойчивой очередью в MongoDB. Теперь робот может продолжить обход после остановки и периодически проверять уже сохранённые страницы. Было полезно разобраться, как связать состояние очереди с сохранением документа и зачем при повторной проверке нужны `ETag`, `Last-Modified` и контрольная сумма ответа.

Я проверил работа тестами и пробной загрузкой в MongoDB. На практике выяснилось, что даже успешный ответ сайта не всегда означает пригодный текстовый документ: в `sitemap` встречаются страницы категорий, а у некоторых публикаций иная разметка. Перед массовой обкачкой нужно уточнить фильтры URL и правила обработки таких страниц, а также следить за расходом места.