МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)
Факультет информационных технологий и прикладной математики

Кафедра вычислительной математики и программирования

Лабораторная работа №5 по курсу «Информационный поиск»

Закон Ципфа

Студент: К. А. Арусланов
Группа: М8О-403Б-23
Преподаватель: А. А. Кухтичев
Дата: 07.11.2026
Оценка:

Москва, 2026

Содержание

1 Постановка задачи **3**

2 Метод решения **3**

2.1 Корпус и единица подсчёта 3

2.2 Подсчёт с ограничением памяти 3

2.3 Модели и разрезы 3

2.4 Проверка корректности 4

3 Результаты **5**

3.1 Общая статистика 5

3.2 Сравнение источников и языковых групп 6

3.3 Программная реализация 7

4 Вывод **7**

1 Постановка задачи

Для своего корпуса необходимо построить график распределения терминов по частотностям в логарифмической шкале, наложить на этот график закон Ципфа. Объяснить причины расхождения.

2 Метод решения

2.1 Корпус и единица подсчёта

Исследуются русскоязычные и англоязычные публикации о компьютерных играх восьми сайтов. Из MongoDB экспортирован локальный снимок из 478 833 пригодных документов: 1 439,91 МБ заголовков и основного текста в UTF-8. 6 514 публикаций участвуют только заголовком. Для всех измерений используется один и тот же снимок корпуса.

Единицей подсчёта является нормализованная словоформа, выделенная на этапе токенизации. Лемматизация не применяется: например, «игра», «игры» и «игрой» учитываются отдельно. В работе исследуется распределение словоформ. Стоп-слова сохраняются, поскольку они составляют наиболее частую часть лексики. Заголовки и основной текст учитываются совместно. Частота f равна общему числу вхождений термина, включая повторения в одном документе.

2.2 Подсчёт с ограничением памяти

Основной алгоритм написан на C++17 без контейнеров STL и готовых структур частотного словаря. Используются собственная хеш-таблица с линейным пробированием и внешняя сортировка. Для каждой группы подсчитывается число вхождений каждого термина. При заполнении выделенного буфера частоты сортируются и сохраняются частями. Последующее слияние суммирует частоты одинаковых терминов из разных частей.

Второй внешний проход упорядочивает пары по убыванию частоты внутри группы. При равенстве используется лексикографическое сравнение UTF-8. Каждому токену присваивается отдельный ранг, начиная с единицы. Весь корпус и весь итоговый словарь не требуется хранить в оперативной памяти. Объём буфера счётчика составляет 64 МиБ; дополнительная память используется для чтения текста и слияния частей.

2.3 Модели и разрезы

Пусть N — число вхождений, V — число различных терминов. Теоретическая кривая закона Ципфа имеет вид

$$f_Z(r) = \frac{C}{r}, \qquad C = \frac{N}{H_V}, \qquad H_V = \sum_{r=1}^{V} \frac{1}{r}.$$

Такая нормировка даёт сумму теоретических частот, равную N. Она не обязывает значение в первой точке совпасть с частотой самого популярного слова. В логарифмических координатах модель является прямой с наклоном -1.

Дополнительно C++ подбирает $f_P(r) = C_P / r^{\alpha}$ линейной регрессией $\ln f = \ln C_P - \alpha \ln r$ на рангах 10–10 000 в пределах словаря группы. Это отдельная оценка наклона выбранного участка распределения. При $\alpha = 1$ модель совпадает по форме с законом Ципфа. Близость показателя к единице на этом интервале не означает совпадения распределений на всех рангах.

На графике эта кривая обозначена как аппроксимация. Для каждого ранга выбранного интервала вводятся $x_r = \ln r$ и $y_r = \ln f_{\text{набл}}(r)$. По этим точкам методом наименьших квадратов оценивается прямая $y = a + bx$, то есть минимизируется

$$\sum_{r=r_{\min}}^{r_{\max}} \left(y_r - a - b x_r\right)^2.$$

После оценки коэффициентов выполняется обратное преобразование: $C_P = e^a$, $\alpha = -b$. Таким образом, по логарифму ранга оценивается логарифм частоты, а в исходных координатах получается степенная кривая. Аппроксимация описывает наклон выбранного участка данных. Для сравнения с законом Ципфа отдельно используется модель с фиксированной степенью 1.

Кроме общего распределения рассчитываются группы по сайтам и языкам источников. Язык определяется по источнику; внутри русскоязычных публикаций могут присутствовать английские названия.

В сравнительных рисунках используется относительная частота f/N каждой группы. Иначе высота линии отражала бы прежде всего объём сайта. Ранг и нормировка вычисляются внутри группы. Один документ участвует в нескольких разрезах: складывать показатели между разрезами нельзя.

2.4 Проверка корректности

План тестирования включает контрольные корпуса с заранее известными частотами, проверку ранжирования и группирования, а также сравнение результатов при разных размерах буфера. Последняя проверка подтверждает, что разбиение на части и многопроходное слияние не изменяют итоговые частоты. Подбор показателя степени проверен на распределении $f(r) = 60/r$ для рангов 1–5, для которого ожидается $\alpha = 1$. Дополнительно проверяется обработка некорректных входных данных.

Успешно пройдены 11 C++-тестов GoogleTest, одна проверка запуска программы и 5 тестов подготовки данных, сравнения и графиков. На полном корпусе проверено, что сумма частот равна числу учтённых токенов, а суммы по сайтам и языкам согласуются с общими показателями. Журнал проверок приложен в `lab5/tests.txt`.

3 Результаты

3.1 Общая статистика

Показатель	Значение
Документы	478 833
Токены N	158 544 765
Различные термины V	1 451 704
Термины с одним вхождением (hapax)	715 896
Доля hapax в словаре, %	49,31
Подобранная степень α	1,0098
Время C++ с чтением и записью, с	123,66

Измерение выполнено для Windows Release-сборки GCC 13.1.0. Приведено время одного запуска с чтением корпуса и записью частот; экспорт данных и построение графиков не учитываются. Использовался прогретый файловый кеш.

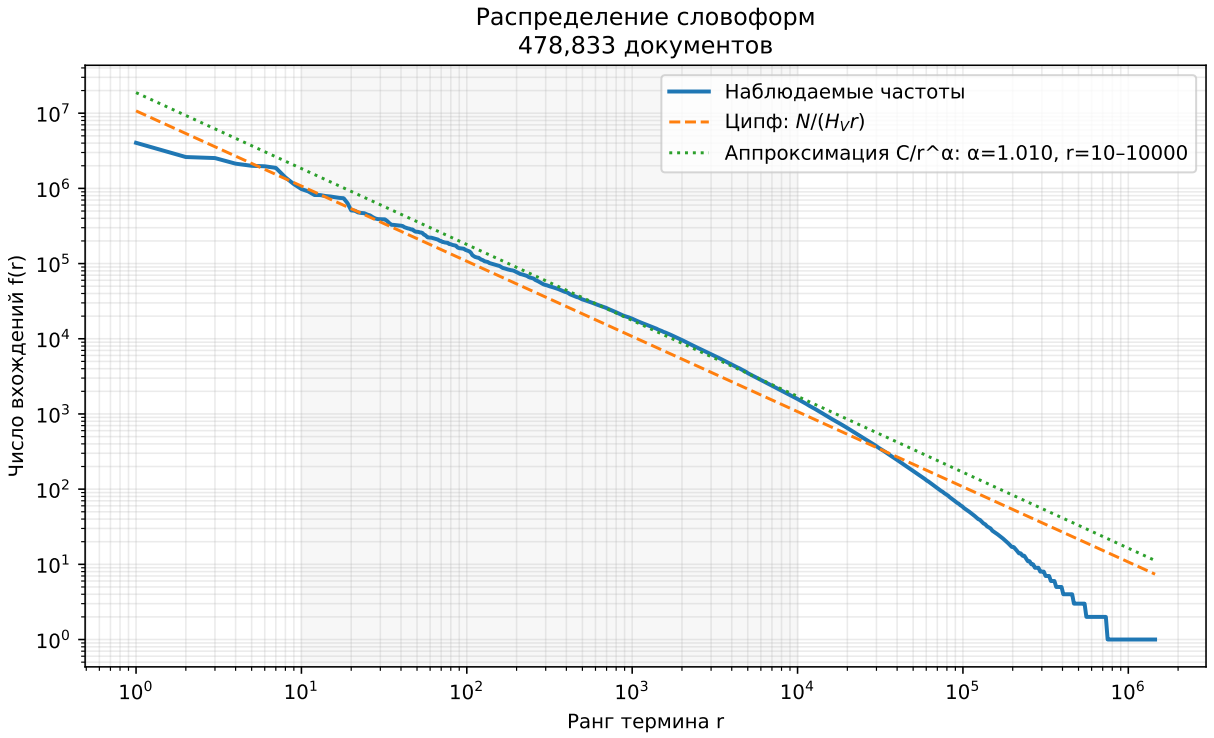


Рис. 1 — Наблюдаемые частоты, закон Ципфа и аппроксимация; серым выделен интервал оценки степени

На средних рангах распределение близко к прямой, а подобранное $\alpha = 1,0098$ близко к единице. Однако в начале кривой и в хвосте наблюдаются отклонения. Почти половина словаря встречается один раз; частоты 1, 2 и 3 образуют ступени, а не гладкую прямую. Число hapax не следует интерпретировать как число опечаток: сюда входят редкие имена, названия, словоформы и нормальные малочастотные слова.

3.2 Сравнение источников и языковых групп

Группа	Документы	Токены	Словарь	α
Весь корпус	478 833	158 544 765	1 451 704	1,010
EN-источники	150 936	76 281 373	476 352	1,197
RU-источники	327 897	82 263 392	1 071 670	0,970
Eurogamer	77 772	39 683 597	307 718	1,192
GameMAG	73 772	13 353 009	364 833	1,011
GamingOnLinux	28 184	9 807 109	110 486	1,313
Игромания	50 818	15 532 575	448 979	0,940
IXBT.games	68 315	12 414 301	314 938	1,007
PC Gamer	44 980	26 790 667	253 863	1,184
PlayGround	80 634	14 421 804	357 310	0,982
StopGame	54 358	26 541 703	636 802	0,967

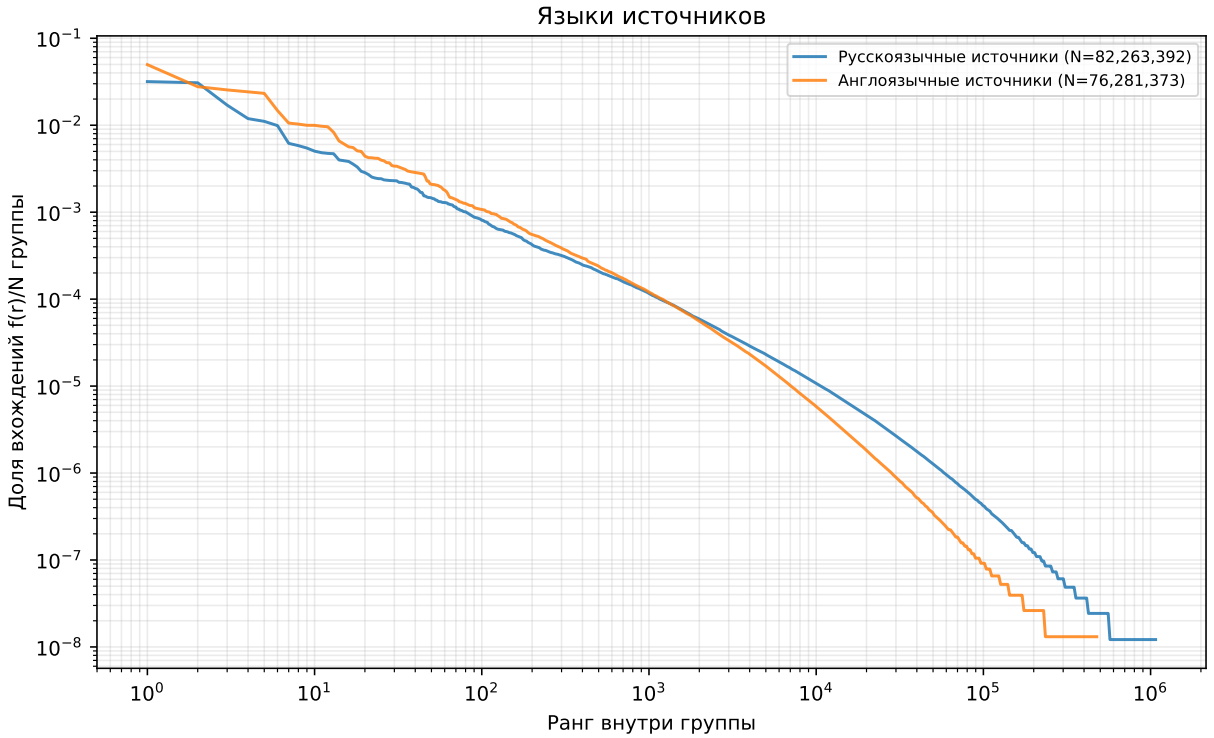


Рис. 2 — Распределения русскоязычных и англоязычных источников

У русскоязычных источников степень на выбранном интервале около 0,970, у англоязычных — 1,197. Русский словарь в этом снимке также больше. Морфологическое разнообразие русского языка может вносить вклад, но этот эксперимент не отделяет его от размера групп, состава сайтов, собственных имён и структуры публикаций. Общая смесь языков даёт свой показатель; переносить его на каждый язык отдельно нельзя.

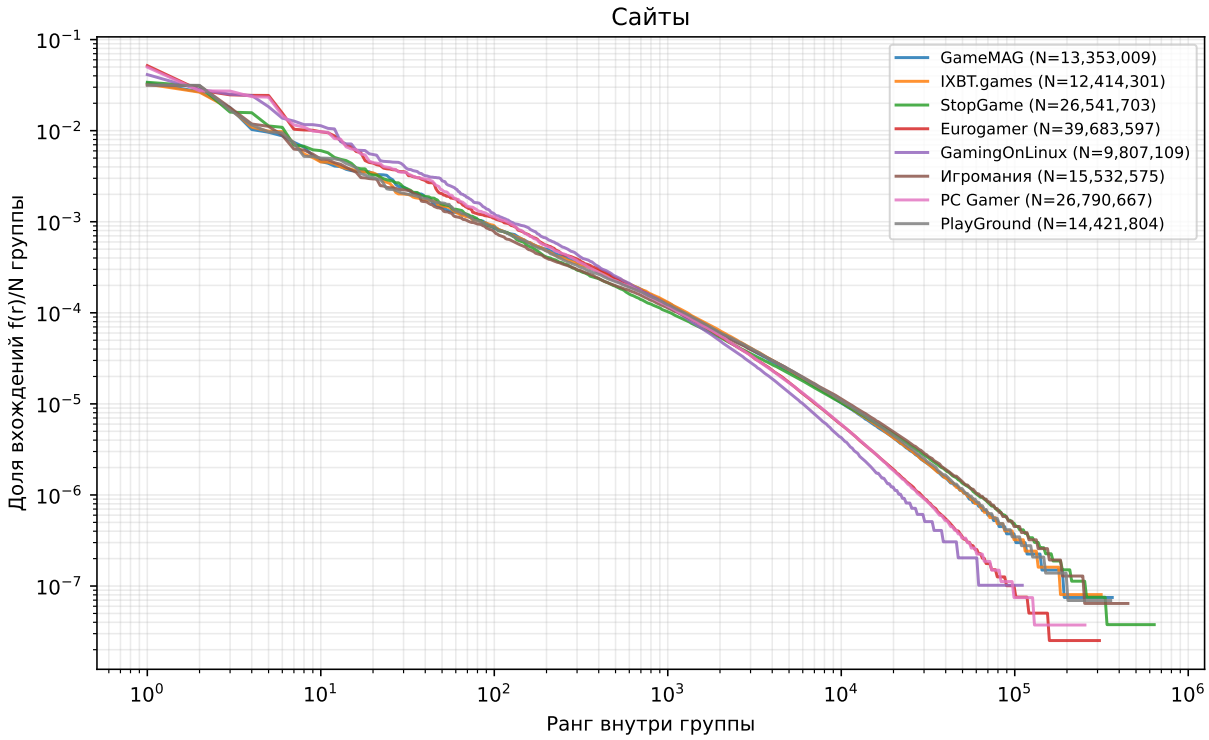


Рис. 3 — Сравнение сайтов после нормировки частот внутри источника

Причины отклонения от идеальной модели — конечный размер корпуса, ограниченная игровая тематика, смесь языков, словоформы, собственные имена и разная длина документов. Сам график не исключает влияния дублей или ошибок парсинга и не оценивает качество поисковой выдачи.

3.3 Программная реализация

Подсчёт частот, ранжирование и подбор показателя степени выполнены на C++. Python используется для подготовки данных и построения графиков. Статистические показатели рассчитаны по всем терминам; на рисунках используется логарифмическая выборка точек распределения. Инструкция сборки и запуска приведена в `doc/lab5_run.md`. Исходный код лабораторной работы: github.com/kirbasss/MAI-IR/tree/lab5.

Рис. 4 — Ссылка на ветку лабораторной работы №5

4 Вывод

В работе построены частотные распределения словоформ игрового корпуса и выполнено сравнение с законом Ципфа. На рангах 10–10 000 общий показатель $\alpha =$

$1,0098$ близок к единице. Основные отклонения наблюдаются среди наиболее частых терминов и в редком хвосте. Однократные термины составляют 49,31% словаря.

Сравнение групп показало различия между русскоязычными и англоязычными источниками. На результаты влияют состав корпуса, морфологическое разнообразие, собственные имена и объём выборки. Поэтому закон Ципфа описывает общую тенденцию, но не задаёт точные частоты отдельных слов.

Для информационного поиска полученное распределение показывает сочетание небольшого числа частых терминов и большого числа редких, расширяющих словарь. Это необходимо учитывать при выборе структуры словаря и способов хранения индекса. Длины списков документов зависят от документных частот и требуют отдельного подсчёта.