МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)
Факультет информационных технологий и прикладной математики

Кафедра вычислительной математики и программирования

**Лабораторная работа №7 по курсу**
**«Информационный поиск»**

# Булев индекс

*Студент*: К. А. Арусланов
*Группа*: М8О-403Б-23
*Преподаватель*: А. А. Кухтичев
*Дата*: 07.11.2026
*Оценка*:

Москва, 2026

# Содержание

**1 Постановка задачи** **3**

**2 Метод решения** **3**
2.1 Представление данных . . . . . 3
2.2 Построение с ограничением памяти . . . . . 3
2.3 Словоформы и леммы . . . . . 3
2.4 Чтение и проверка . . . . . 4
2.5 План тестирования . . . . . 4

**3 Результаты** **4**
3.1 Объём индекса . . . . . 4
3.2 Примеры списков документов . . . . . 5
3.3 Время и память . . . . . 5
3.4 Повторение работы . . . . . 6

**4 Вывод** **6**

# 1 Постановка задачи

Построить булев индекс корпуса документов для последующего поиска. Индекс должен сопоставлять термину список документов, в которых он встречается, исключать повторные ID и обеспечивать доступ к спискам без последовательного просмотра исходных текстов. Структуры индекса реализовать самостоятельно на C++ с учётом обработки корпуса, не помещающегося целиком в оперативную память.

# 2 Метод решения

## 2.1 Представление данных

Используется фиксированный снимок русскоязычных и англоязычных публикаций о компьютерных играх из восьми источников. Индексируются заголовки и основной текст. Документы имеют уникальные возрастающие 64-битные ID.

Для термина $t$ хранится список

$$L(t) = \{d : \ t \text{ встречается в документе } d\}, \qquad df(t) = |L(t)|.$$

Список упорядочен по возрастанию ID и не содержит повторений. Несколько вхождений слова в одной статье и совпадение в разных полях дают одну запись. Поэтому $df$ отличается от частоты вхождений, рассчитанной при изучении закона Ципфа.

Индекс содержит словарь терминов, последовательные списки документов и таблицу метаданных. В записи словаря сохраняются смещение списка и число его элементов. Заголовки, URL и источники доступны по ID документа без обращения к MongoDB.

## 2.2 Построение с ограничением памяти

Программа написана на C++17 без готовых контейнеров STL для структур индекса. Из текста формируется поток пар «термин, ID документа». Собственная хеш-таблица исключает одинаковые пары в текущем буфере. При заполнении буфера пары сортируются собственной пирамидальной сортировкой и сохраняются в промежуточную часть.

Части сливаются с помощью собственной двоичной кучи. При совпадении пар записывается только одна из них. Если частей много, слияние выполняется в несколько проходов; за проход открыто не более 24 входов. Итоговый поток упорядочен сначала по термину, затем по ID документа. Из него последовательно записываются словарь и списки.

Размер буфера пар составляет 64 МиБ. Корпус и все списки одновременно в память не загружаются. Дополнительная память используется для текущего текстового поля, буферов слияния и морфологического словаря.

## 2.3 Словоформы и леммы

В одном индексе предусмотрены два независимых пространства терминов. Первое хранит исходные нормализованные словоформы. Второе строится с использованием словарного лемматизатора из ЛР4. Неизвестные слова сохраняются, а при

неоднозначном разборе документ включается в списки всех различных лемм. В каждом отдельном списке его ID остаётся уникальным.

Например, слово «стали» может добавить документ к спискам «сталь» и «стать». Это расширение множества кандидатов; контекстное снятие омонимии не выполняется. Исходное пространство позволяет позднее сравнивать точные совпадения и поиск по леммам. В отличие от частотного эксперимента здесь фиксируется наличие термина в документе, поэтому альтернативные разборы не интерпретируются как дополнительные исходные вхождения.

### 2.4 Чтение и проверка

Записи словаря имеют фиксированный размер и расположены в лексикографическом порядке. Поиск выполняется бинарно на диске. После нахождения записи список читается потоковым курсором. Курсоры имеют независимые позиции, что позволяет в следующей работе выполнять пересечение, объединение и разность списков.

Сохраняются версия формата, правила нормализации и контрольные суммы. Проверка готового индекса последовательно читает данные, сверяет целостность файлов, порядок словаря, уникальность ID и их принадлежность множеству документов. Незавершённый индекс не допускается к чтению.

### 2.5 План тестирования

GoogleTest проверяет точные списки на контрольных корпусах, устранение дублей между полями и промежуточными частями, работу с произвольными 64-битными ID, пустые документы и документы только с заголовком. Проверяются пространства словоформ и лемм, неоднозначные разборы, независимость курсоров и получение метаданных без исходного корпуса.

Синтетический корпус вызывает несколько проходов слияния. Итоговые файлы побайтово сравниваются с индексом, построенным при большем буфере. Проверяются также повреждения данных, несогласованный каталог URL, незавершённое построение и защита существующего результата.

Успешно пройдены 10 GoogleTest и одна проверка запуска CLI. Дополнительно выполнены 3 Python-теста подготовки каталога URL. Python не участвует в построении словаря или списков документов. Журнал приложен в `lab7/tests.txt`.

## 3 Результаты

### 3.1 Объём индекса

Индекс построен на 478 833 документах, содержащих 158 544 765 исходных токенов. Число токенов и размер словаря словоформ совпали с результатами ЛР5 на том же снимке.

| Показатель | Словоформы | Леммы |
|---|---:|---:|
| Термины | 1 451 704 | 1 093 912 |
| Пары «термин, документ» | 90 681 947 | 91 302 977 |

Словарь лемм меньше словаря словоформ, однако число пар «лемма, документ» несколько больше. Это связано с включением документа в списки всех различных разборов: уменьшение числа терминов не гарантирует уменьшения суммарного числа элементов списков.

| Файл | Размер, МБ |
|---|---|
| terms.bin | 101,82 |
| postings.bin | 1 455,88 |
| documents.bin | 30,65 |
| strings.bin | 129,87 |
| Всего | 1 718,22 |

ID в списках хранятся без сжатия, по 8 байт. В общий размер входят оба пространства терминов и метаданные документов. Поэтому этот размер не следует сравнивать с индексом только словоформ или со сжатым представлением. Сжатие списков и ускорение их пересечения относятся к последующим работам.

## 3.2 Примеры списков документов

Программа позволяет обратиться к отдельному термину без чтения корпуса. В таблице приведены реальные документные частоты и первые пять ID из сохранённых списков пространства словоформ. Многоточием обозначено продолжение списка; ID относятся к исследуемому снимку.

| Термин | Пространство | *df* | Начало списка |
|---|---|---|---|
| doom | Словоформы | 7 469 | [72, 133, 165, 595, 747, ...] |
| minecraft | Словоформы | 5 824 | [272, 316, 368, 530, 536, ...] |
| skyrim | Словоформы | 4 635 | [446, 665, 1118, 1310, 1419, ...] |

## 3.3 Время и память

| Показатель | Значение |
|---|---|
| Построение C++ с чтением и записью, с | 688,26 |
| Полная проверка готового индекса, с | 21,39 |
| Пиковый рабочий набор при построении, МиБ | 208,30 |
| Пиковый рабочий набор при проверке, МиБ | 4,43 |
| Буфер пар, МиБ | 64 |
| Морфологический словарь, МБ | 166,54 |
| Промежуточные части | 174 |
| Проходы слияния | 2 |

Измерение выполнено для нативной Windows Release-сборки GCC 13.1.0. Приведён один прогон, а не медиана нескольких измерений. Подготовка каталога URL и

вычисление SHA-256 обвязкой не включены во время построения C++. Рабочий набор означает резидентную память процесса; размер выделенных буферов и занятые страницы могут различаться.

Результат подтверждает возможность построения индекса выбранного снимка с ограниченным буфером. Производительность на миллионном корпусе этим прогоном не проверялась. При увеличении данных дополнительно потребуются временное место на диске и проходы слияния.

### 3.4 Повторение работы

Инструкция сборки, запуска и инспекции отдельных списков приведена в `doc/lab7_run.md`. Реализация сохраняет индекс и предоставляет интерфейс его чтения. Разбор булевых выражений и поисковая выдача реализуются в ЛР8; оценка релевантности не относится к проверке целостности построенного индекса.

Исходный код: github.com/kirbasss/MAI-IR/tree/lab7.

Рис. 1 — Ссылка на ветку лабораторной работы №7

## 4 Вывод

Построен булев инвертированный индекс игрового корпуса. Повторные вхождения объединены в уникальные пары «термин, документ», списки упорядочены и проверены на согласованность с документным множеством. Раздельное хранение словоформ и лемм позволяет использовать одну структуру для сравнения режимов поиска.

Внешняя сортировка и слияние ограничивают объём рабочего буфера, а дисковый словарь и потоковые курсоры позволяют читать индекс без загрузки всех терминов и списков в память. Следующий этап — булев поиск по сохранённому индексу. Его ограничения на текущем этапе: отсутствие сжатия и координат слов, а также возможные лишние кандидаты при неоднозначной лемматизации.