МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)
Факультет информационных технологий и прикладной математики

Кафедра вычислительной математики и программирования

Лабораторная работа №14 по курсу «Информационный поиск»

Построение сниппетов поисковой выдачи

Студент: К. А. Арусланов
Группа: М8О-403Б-23
Преподаватель: А. А. Кухтичев
Дата: 08.11.2026
Оценка:

Москва, 2026

Содержание

1 Постановка задачи **3**

2 Метод решения **3**
2.1 Доступ к исходному тексту 3
2.2 Выбор фрагмента 3

3 План тестирования **4**

4 Результаты **4**
4.1 Проверка на полном снимке 4
4.2 Автотесты 6

5 Вывод **6**

1 Постановка задачи

Для найденных документов построить короткие фрагменты исходного текста, объясняющие совпадение с запросом. Показывать сниппеты в командной строке и веб-выдаче. Результаты поиска и их порядок должны сохраняться.

2 Метод решения

2.1 Доступ к исходному тексту

Поисковый индекс ЛР7–ЛР13 хранит заголовки и координаты, но не тела документов. Тексты находятся в неизменяемом снимке MAIIR3 из 478,833 документов. Для быстрого доступа создан отдельный файл смещений: для каждого ID записаны положение и длина заголовка и текста. Файл создаётся однократно потоковым проходом по снимку и занимает 19,153,352 байта; тела документов в оперативную память при построении не загружаются. При запросе читаются только тексты показанных документов.

Файл смещений содержит версию формата, размер снимка, число документов и контрольную сумму записей. При открытии проверяются границы и порядок ID. Заголовок каждого показанного документа сравнивается побайтово с заголовком из поискового индекса. Это защищает от случайной подмены снимка или смещений. При отсутствии файла CLI может восстановить смещения при открытии, но такой путь не подходит для частых запросов.

2.2 Выбор фрагмента

Исходный текст делится на предложения по точке, вопросительному и восклицательному знакам перед пробелом, а также по переводу строки. Токенизация использует те же правила `gaming-v3`, что и индекс. В режиме лемм варианты терминов сопоставляются через тот же словарь. Для предложения подсчитываются число разных слов запроса и число совпадений. Компактное расположение совпадений повышает оценку; при равенстве предпочтение отдаётся более раннему предложению. Если в тексте нет слов запроса, показывается его начало.

После выбора предложения сниппет расширяется соседними предложениями в пределах того же абзаца. Это даёт контекст коротким предложениям и не захватывает соседние блоки рекомендаций сайта. Фрагмент ограничивается 600 байтами, по возможности вокруг первого совпадения. Обрезка выполняется только на границе символа UTF-8. Ответ CLI содержит сам текст, байтовые диапазоны совпадений внутри него и признаки обрезки слева и справа. Веб-форма преобразует эти диапазоны в подсветку `<mark>` после HTML-экранирования фрагмента. Текст сниппета выводится меньшим, приглушённым серым шрифтом; совпавшие слова остаются контрастными. Код выбора и хранения смещений написан на C++ без STL-контейнеров.

3 План тестирования

Случай	Ожидаемый результат
Несколько предложений	Выбирается лучшее, добавляются соседи из того же абзаца
Русский UTF-8	Диапазоны выделяют полные слова в байтовой строке
Прямое чтение и файл смещений	Сниппеты и порядок результатов одинаковы
Повреждённый файл смещений	Ошибка контрольной суммы до выдачи документов
Текст отсутствует	Пустой сниппет без ошибки поиска
HTML в тексте документа	Теги экранированы; подсвечены только слова запроса
Реальный снимок и веб-форма	CLI возвращает фрагменты, HTTP-ответ содержит подсветку

Шесть GoogleTest вызывают C++-поиск на синтетическом корпусе: проверяют выбор предложения, точность UTF-8 диапазонов, совпадение двух способов чтения, отказ на повреждении, привязку снимка к индексу, обрезку длинного предложения и пустой текст. Три Python unittest проверяют передачу параметров ядру и безопасное отображение HTML. Весь набор предыдущих лабораторных также запущен на текущих исходниках.

4 Результаты

4.1 Проверка на полном снимке

Файл смещений успешно построен для 478,833 документов. Скрипт `run_lab14.py` выполнил пять запросов на упакованном индексе: TF-IDF по словоформам и леммам, а также булев поиск. Для запроса `doom AND eternal` булев поиск нашёл 1,392 документа; для первого результата выбран фрагмент о выпуске Doom Eternal. Для TF-IDF запроса `doom eternal` найдено 9,170 документов; первые пять результатов и сниппеты сохранены в `lab14/examples.json`. HTTP-запрос к веб-форме вернул код 200, на сохранённой странице `lab14/web_example.html` есть 27 подсвеченных вхождений. Для запроса `"игры ps plus"` AND `сентябрь` по леммам найдено шесть документов. У первых двух короткое предложение со словами запроса расширилось до полного абзаца: 559 и 542 байта вместо одной строки. У третьего документа слова встречаются только в блоке «Читайте также»; переходить в соседний абзац здесь означало бы показывать чужой контекст.

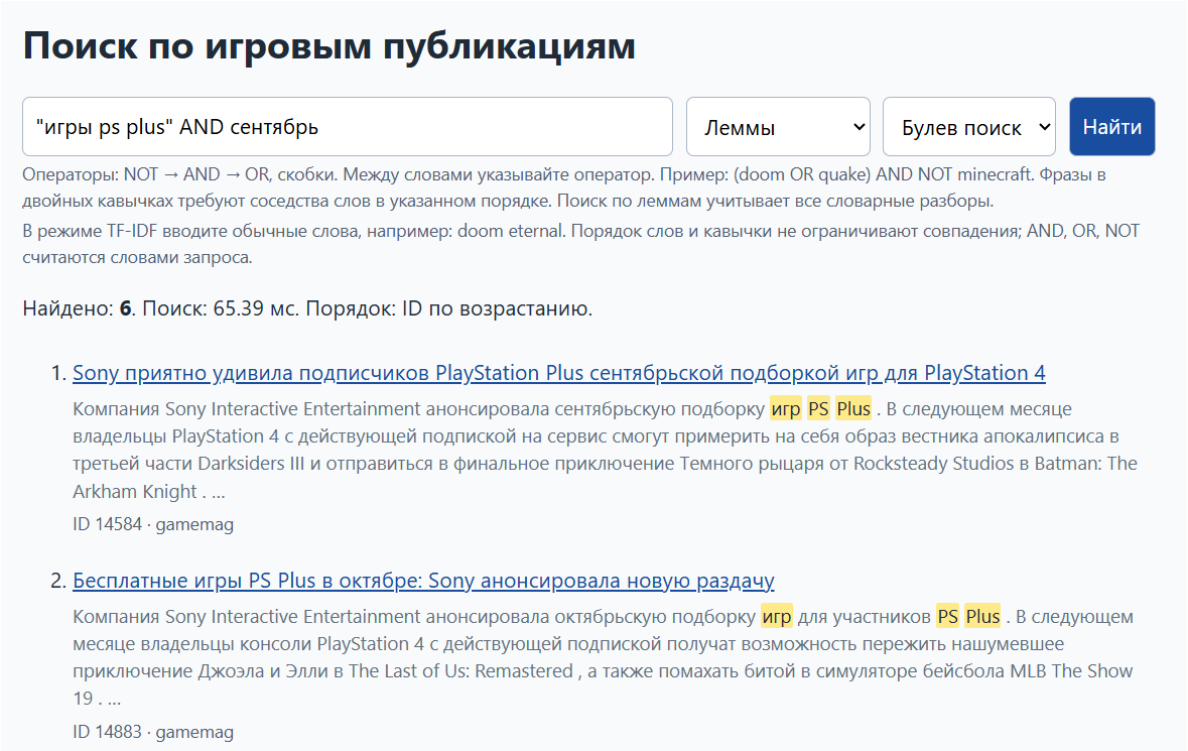


Рис. 1 — Булев поиск по леммам: запрос `"игры ps plus" AND сентябрь`; два первых результата с расширенными сниппетами

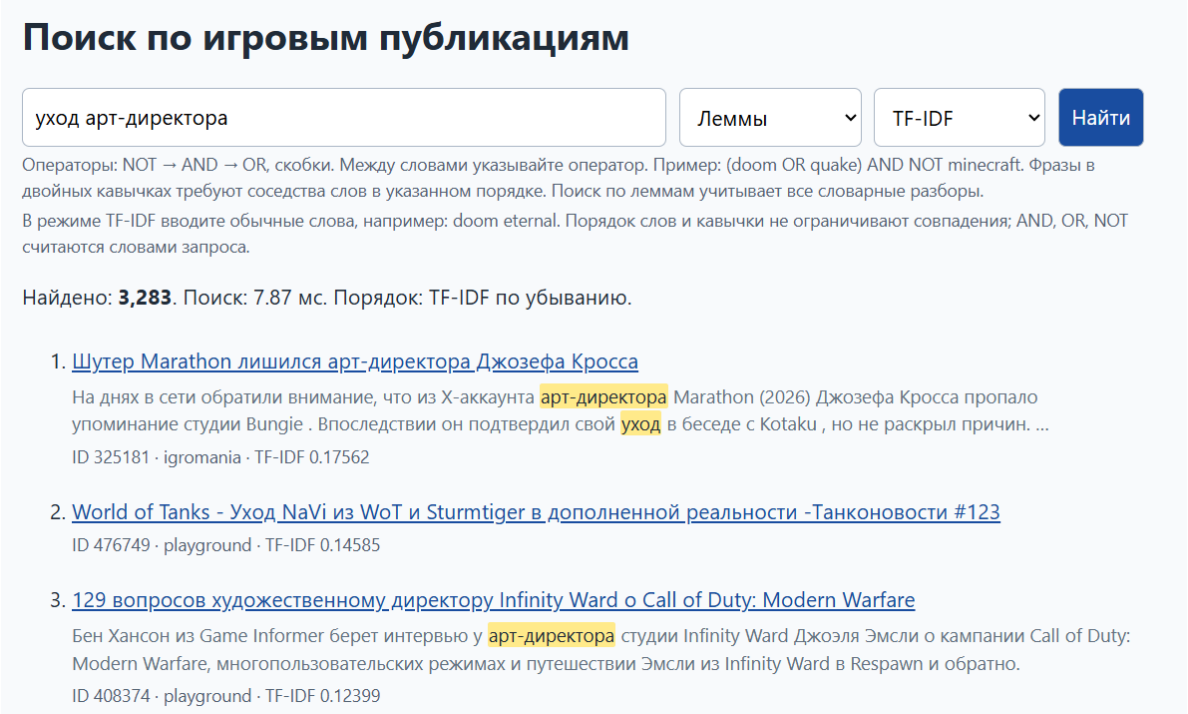


Рис. 2 — TF-IDF по леммам: запрос «уход арт-директора»; у второго результата текст документа отсутствует, поэтому сниппет пуст

С файлом смещений полный вызов CLI для запроса `doom eternal` занял 0,149 с. Первый вариант, просматривавший снимок при каждом запросе, требовал около 9 с. Это наблюдения одного запуска при тёплом кэше, включая открытие индекса и подготовку выдачи, а не гарантированное время ответа на другом компьютере.

4.2 Автотесты

Тесты ЛР14: 6/6 GoogleTest и 3/3 Python unittest. Полный регрессионный прогон: 153/153 CTest и 294/294 Python-тестов, без пропусков; для интеграционных проверок запущена отдельная временная MongoDB. Отдельные тестовые случаи и результаты записаны в `lab14/full/tests.txt`; сводка находится в `lab14/full/summary.json`.

Исходники, команды сборки и повторения эксперимента описаны в `lab14_run.md`. Исходный код: github.com/kirbasss/MAI-IR/tree/lab14.

Рис. 3 — Ссылка на ветку лабораторной работы №14

5 Вывод

Сниппеты делают причину совпадения видимой прямо в выдаче и работают поверх обоих режимов поиска без изменения ранжирования. Для документов, у которых в снимке сохранён только заголовок, текстового фрагмента нет. Независимо от этого короткие предложения могут почти повторять заголовок. Простое правило границ предложений иногда ошибается на сокращениях, а ограничение в 600 байт может отрезать полезный контекст. В дальнейшем можно учитывать совпадение с заголовком и тип публикации, а также лучше отделять основной текст от рекомендаций сайта.